Critérios de governança da interação por voz

FIAP — Faculdade de Informática e Administração Paulista
Inteligência Artificial

Rodrigo Wolkoff Giorgi — RM 556980
Carlos Mamede Eduardo — RM 568269

Critérios de governança da interação por voz
Acesso, privacidade, rastreabilidade, confirmação humana e limites da IA do agente Raly

São Paulo
2026

Rodrigo Wolkoff Giorgi — RM 556980
Carlos Mamede Eduardo — RM 568269

Critérios de governança da interação por voz

Acesso, privacidade, rastreabilidade, confirmação humana e limites da IA do agente Raly

Relatório apresentado à disciplina Governança em IA e Business Analytics do curso Inteligência Artificial da FIAP — Faculdade de Informática e Administração Paulista, como requisito da Sprint 1 do Challenge Motiva.

Professor: Marco Antonio Russi Fontoura

São Paulo
2026

Lista de figuras

1. Figura 1 – Cadeia Dado → Informação → Conhecimento → Inteligência no agente Raly.....10
2. Figura 2 – Storyboard de diálogo do registro e da consulta por duas personas 14

Lista de tabelas

1. Tabela 1 – Matriz de permissões por persona (interação por voz).....6
2. Tabela 2 – Matriz RACI para três decisões de governança.....8
3. Tabela 3 – Inventário de dados e bases legais.....8
4. Tabela 4 – Cadeia D-I-C-I aplicada.....10
5. Tabela 5 – Metadados obrigatórios do log de auditoria.....10
6. Tabela 6 – Matriz de confirmação humana por criticidade.....11
7. Tabela 7 – Limites da IA.....12
8. Tabela 8 – Quadro de integração com as demais disciplinas.....13
9. Tabela 9 – Critérios evidenciados no storyboard.....14

Sumário

1 INTRODUÇÃO.....6
2 ENTREGA 1 — ACESSO E PRIVACIDADE.....6
2.1 Personas e princípio do menor privilégio.....6
2.2 Matriz de permissões por voz.....6
2.3 Matriz RACI de governança.....7
2.4 Inventário de dados e bases legais.....8
3 ENTREGA 2 — RASTREABILIDADE, CONFIRMAÇÃO HUMANA E LIMITES DA IA.....10
3.1 Cadeia D-I-C-I.....10
3.2 Log de auditoria.....10
3.3 Matriz de confirmação humana.....11
3.4 Limites da IA.....12
3.5 Risco de viés com sotaques regionais.....12
4 INTEGRAÇÃO COM AS DISCIPLINAS DA SPRINT.....13
5 ROTEIRO DE INTERAÇÃO GOVERNADA.....13
6 CONSIDERAÇÕES FINAIS.....14
DECLARAÇÃO DE USO DE IA 15

1 Introdução

O Challenge Motiva propõe um agente de voz para apoiar profissionais de operação rodoviária e manutenção em campo. O agente da equipe, chamado **Raly**, permite consultar e registrar informações por comando de voz — por exemplo, registrar uma ocorrência no km 82 ou ouvir o resumo de uma missão de guincho. Como o agente lida com voz, localização, dados de vítimas e ações que mobilizam recursos, ele precisa nascer governado (*Ethics by Design*).

Este relatório define os critérios iniciais de acesso, privacidade, rastreabilidade, confirmação humana e limites da IA que orientam o protótipo desde a Sprint 1. O documento está organizado em duas entregas: a Entrega 1 trata de quem acessa o quê e com qual base legal; a Entrega 2 trata da cadeia Dado–Informação–Conhecimento–Inteligência (D-I-C-I), do log de auditoria, da matriz de confirmação humana e dos limites da IA. Ao final, apresentam-se a integração com as demais disciplinas da Sprint e o roteiro de interação governada. Trata-se do início de uma documentação viva, que será revisada a cada sprint.

2 Entrega 1 — Acesso e privacidade

2.1 Personas e princípio do menor privilégio

As cinco personas das User Stories da Motiva têm necessidades distintas. Aplicamos o menor privilégio: cada perfil ouve e registra apenas o necessário para sua tarefa, e as permissões são verificadas no servidor antes de qualquer busca de dados — não na interface. Legenda das matrizes: ✔ permitido; ◖ permitido com restrição; ✘ não permitido.

2.2 Matriz de permissões por voz

Tabela 1 — Matriz de permissões por persona (interação por voz)

Ação / dado	Inspeção de Tráfego	Guincho / Recurso	APH	Supervisor	Coordenador / Gerente
Consultar ocorrências do próprio trecho/missão	✔	◖ só a missão atribuída	◖ só o atendimento atribuído	✔	✔

Ação / dado	Inspeção de Tráfego	Guincho / Recurso	APH	Supervisor	Coordenador / Gerente
Consultar procedimentos operacionais aprovados	✔	✔	✔	✔	✔
Consultar protocolos clínicos aprovados (APH)	✘	✘	✔	✘	✘
Ouvir dados clínicos da vítima	✘	✘ recebe apenas "há vítima no local"	✔	◖ agregado (nº e gravidade)	◖ agregado anonimizado
Registrar ocorrência	✔	✘	◖ dados do atendimento	✔	✘
Atualizar status	✔	◖ etapas do serviço	◖ status do atendimento	✔	✘
Solicitar apoio/recurso adicional	✔	✔	✔	✔	✘
Validar registros inconsistentes	✘	✘	◖ os próprios	✔	◖ por amostragem
Encerrar atendimento/missão	◖ após confirmação	◖ a própria missão	◖ o próprio atendimento	✔	✘
Registrar direcionamento operacional	✘	✘	✘	◖ do turno	✔ mediante validação
Consultar indicadores e sínteses	✘	✘	✘	◖ do turno	✔

Fonte: Elaborado pelos autores (2026)

Exemplo do enunciado. O Agente de Guincho **não** ouve os dados clínicos da vítima ao receber o resumo da missão. Para sua segurança e para o planejamento da remoção, basta saber que há vítima no local e que deve aguardar a liberação do APH. Os dados de saúde são sensíveis (LGPD, art. 11) e sua finalidade se esgota no atendimento pré-hospitalar.

2.3 Matriz RACI de governança

Papéis considerados: **Data Owner** (dono do processo e dos dados: Gerência de Operações); **Data Steward** (qualidade e significado dos dados: Supervisão/Qualidade Operacional); **Data Custodian** (guarda técnica: TI/Engenharia de Dados); **DPO** (Encarregado de Proteção de Dados); **AI Ethics Officer** (responsável pelos riscos éticos e pelo comportamento do modelo). R = executa; A = responde pela decisão (um único por linha); C = consultado; I = informado.

Distribuição dos papéis no grupo na Sprint 1: Rodrigo Wolkoff Giorgi atua como Data Owner, DPO e AI Ethics Officer; Carlos Mamede Eduardo atua como Data Steward e Data Custodian. Esta é uma distribuição acadêmica entre os dois integrantes e não substitui designações formais da Motiva.

Tabela 2 — Matriz RACI para três decisões de governança

Decisão	Data Owner	Data Steward	Data Custodian	DPO	AI Ethics Officer
Aprovar a base de procedimentos e protocolos que o agente consulta	A	R	C (versiona e indexa)	C (dados pessoais nos documentos)	C (risco de resposta indevida)
Validar registros inconsistentes gerados por voz	I	A / R (supervisor revisa)	C (trilha técnica)	I (se houver dado sensível)	C (padrões de erro do modelo)
Responder por um erro do agente em campo	A (resposta à operação e ao poder concedente)	R (análise do registro)	R (preserva logs e evidências)	C (incidente com dado pessoal)	R (causa-raiz, ajuste e prevenção)

Fonte: Elaborado pelos autores (2026)

Nota da equipe: conforme o barema, a RACI deve expressar decisões autorais do grupo. Cada integrante deve discutir e justificar as responsabilidades, aprovar a versão final e remover qualquer conteúdo que permaneça apenas como sugestão inicial de IA.

2.4 Inventário de dados e bases legais

Tabela 3 — Inventário de dados e bases legais

Dado	Categoria	Finalidade	Base legal (LGPD)	Retenção proposta
Voz dos profissionais (áudio do comando)	Pessoal (não usada como biometria no MVP)	Transcrever o comando	Art. 7º, V (se necessário ao contrato de trabalho) ou IX c/c art. 10, após teste de balanceamento.	Áudio descartado após a confirmação do registro; amostra de até 30 dias para auditoria de qualidade
Identificação por voz (verificação de locutor) — futuro	Sensível (biométrico, art. 5º, II)	Garantir que comando crítico vem do operador	Art. 11, II, “g”, se indispensável; avaliar direitos do titular e salvaguardas.	Modelo de voz enquanto durar o vínculo

Dado	Categoria	Finalidade	Base legal (LGPD)	Retenção proposta
Transcrição e registro da ocorrência	Pessoal (autor) / operacional	Registro e rastreabilidade do atendimento	Art. 7º, II, se houver obrigação legal/regulatória específica; ou IX c/c art. 10, com teste. Concessão, isoladamente, não basta.	Conforme tabela de temporalidade validada; cinco anos é hipótese.
Geolocalização do profissional	Pessoal	Localizar a ocorrência e o recurso	Art. 7º, V (se necessário ao contrato de trabalho) ou IX c/c art. 10, após teste. Coleta só durante uso autorizado.	Vinculada ao registro; trilha contínua de GPS não é armazenada pelo agente
Dados de saúde da vítima (APH)	Sensível (art. 11)	Atendimento pré-hospitalar e continuidade do cuidado	Art. 11, II, “e” (vida/incolumidade física) ou “f” (tutela da saúde por agente qualificado), conforme o caso.	Prazo do prontuário de atendimento definido pelo responsável técnico; acesso restrito ao APH
Dados de identificação de vítimas e envolvidos	Pessoal	Registro do atendimento e comunicação a órgãos	Art. 7º, II, se houver dever legal/regulatório; ou VII, para proteção à saúde no procedimento legalmente previsto.	Conforme a temporalidade da concessão
Vozes de terceiros captadas pelo microfone	Pessoal (eventual), não intencional	Nenhuma — subproduto indesejado	Sem uso autônomo: evitar captação; descartar captura incidental, sem transcrever ou reutilizar. Avaliar tratamento residual.	Descartadas com o áudio; nunca vão ao log
Log de auditoria	Pessoal (pseudonimizado)	Rastreabilidade e apuração de incidentes	Art. 7º, II, se houver dever específico; ou IX c/c art. 10, após teste de balanceamento.	Prazo conforme finalidade e tabela validada; cinco anos é hipótese.
Indicadores agregados	Agregado; anonimizado somente após avaliar risco de reidentificação (art. 12).	Gestão e melhoria contínua	Fora do escopo da LGPD quando anonimizado (art. 12)	Indeterminada

Fonte: Elaborado pelos autores (2026). Bases e prazos são propostas iniciais e dependem de validação pelo controlador, DPO/encarregado e jurídico.

3 Entrega 2 — Rastreabilidade, confirmação humana e limites da IA

3.1 Cadeia D-I-C-I

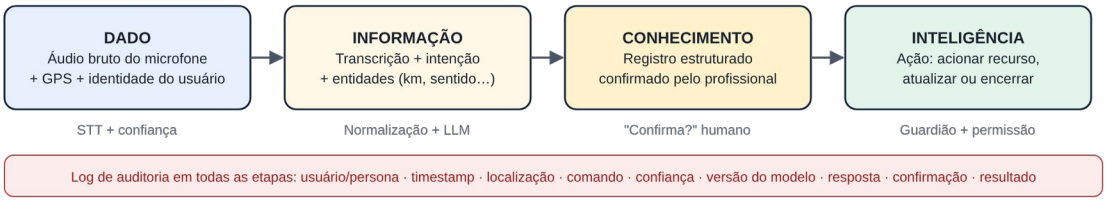


Figura 1 *— Cadeia Dado → Informação → Conhecimento → Inteligência no agente Raly. Fonte: Elaborado pelos autores (2026).*

Tabela 4 — Cadeia D-I-C-I aplicada

Nível	No agente Raly	Exemplo	Quem controla
Dado	Áudio, GPS, identidade e persona do usuário	Arquivo de áudio de 4 s; lat/long; usuário insp_017	Sistema (coleta mínima)
Informação	Transcrição, intenção e entidades extraídas	"registrar_ocorrencia"; km 82; sentido capital; confiança 0,91	Modelos (STT, PLN, LLM)
Conhecimento	Registro estruturado, validado e confirmado	Ocorrência 2026-0458 confirmada pelo inspetor	Profissional (confirmação)
Inteligência	Ação ou decisão operacional	CCO aciona APH; supervisor prioriza	Pessoas com permissão

Fonte: Elaborado pelos autores (2026)

3.2 Log de auditoria

Tabela 5 — Metadados obrigatórios do log de auditoria

Campo	Descrição	Exemplo
id_evento	Identificador único e imutável	ev_7f3a…
usuario / persona	Quem falou e com qual perfil	insp_017 / inspecao_trafego
timestamp	Data e hora (UTC e local)	2026-10-19T21:14:08-03:00
localizacao	Coordenada e referência viária	-23.18,-46.88 · SP-348 km 82 sentido capital
comando	Transcrição do pedido (sem áudio)	"registra acidente com vítima…"
confianca_stt	Score de confiança da transcrição	0,91
intencao / criticidade	Intenção reconhecida e nível	registrar_ocorrencia / registro

Campo	Descrição	Exemplo
versao_modelo	Versões de STT, LLM, prompt e base RAG	whisper-small-pt 1.2 · llm 2026.10 · prompt v7 · base v3
resposta	O que o agente falou/mostrou	"Vou registrar… Confirma?"
confirmacao	Resposta do usuário e forma	"confirmo" por voz, 21:14:20
resultado	Efeito no sistema	registrado · protocolo 2026-0458
hash_anterior	Encadeamento que torna o log à prova de adulteração	sha256…

Fonte: Elaborado pelos autores (2026)

3.3 Matriz de confirmação humana

Tabela 6 — Matriz de confirmação humana por criticidade

Criticidade	Exemplos de intenção	Confirmação exigida	Se o agente não entender
Consulta	Ouvir resumo do trecho; consultar procedimento; consultar recursos acionados	Nenhuma — mas a resposta cita a fonte e a hora da informação	"Não entendi. Você quer o procedimento ou o status?" (uma pergunta)
Registro	Registrar ocorrência; informar localização e condições; marcar horários	Leitura do resumo + "confirmo" verbal ou toque no cartão; dados críticos (km, sentido) repetidos	Pede o campo faltante ou ambíguo; não grava rascunho como definitivo
Acionamento	Solicitar apoio; solicitar recurso adicional; atualizar status que mobiliza equipes	Confirmação explícita com repetição do recurso e local + verificação de que a voz é do operador autenticado; CCO mantém a decisão final	Não aciona; informa "não acionei nada" e oferece repetir
Encerramento	Encerrar atendimento; finalizar missão; validar registro	Resumo das providências + confirmação dupla (voz e toque) + campos obrigatórios completos	Mantém aberto e lista o que falta

Fonte: Elaborado pelos autores (2026)

Regra geral para comandos não compreendidos: o agente nunca adivinha. Se a transcrição vier vazia ou com confiança baixa, diz que não ouviu; se entender parte, pergunta especificamente o que faltou; se o modelo estiver fora do ar, informa a indisponibilidade e preserva o rascunho para envio posterior.

3.4 Limites da IA

Tabela 7 — Limites da IA

Limite	Risco que controla	Como é implementado
Não sugerir conduta clínica no APH	Dano à vítima; atuação fora da competência	O agente só lê protocolos aprovados quando o APH pede; pedidos como "o que eu faço com a vítima?" recebem: "Siga o protocolo e a regulação médica".
Responder apenas com procedimentos aprovados (controle de alucinação)	Procedimento inventado ou desatualizado	RAG restrito à base aprovada pelo Data Owner, com versão e vigência; sem trecho relevante, o agente se abstém e cita a fonte quando responde.
Não executar comandos críticos vindos de voz de terceiros ou áudio ambiente (controle de prompt injection)	Acionamento falso por rádio, passageiro ou vídeo	Push-to-talk ou wake word do usuário autenticado; comandos críticos exigem confirmação do mesmo operador; texto transcrito é tratado como dado.
Não afirmar que algo foi registrado ou acionado sem confirmação do sistema	Falsa sensação de que o socorro está a caminho	A fala de sucesso só é gerada após retorno do sistema; falhas são ditas explicitamente.
Não inferir emoção, saúde ou culpa pela voz	Discriminação e decisões injustas	Recurso não implementado e vedado na política.

Fonte: Elaborado pelos autores (2026)

3.5 Risco de viés com sotaques regionais

A Motiva opera em 13 estados; um modelo de reconhecimento de fala treinado majoritariamente com português do Sudeste pode errar mais com sotaques nordestinos, sulistas ou do interior, gerando mais pedidos de repetição e registros errados para esses profissionais. Medição proposta: montar um conjunto de teste com comandos operacionais gravados por profissionais de diferentes regiões, gêneros e faixas etárias, com e sem ruído de rodovia; calcular a taxa de erro de palavras (WER) e a acurácia de intenção e de entidades críticas (km, sentido) por grupo; considerar viés relevante uma diferença superior a 5 pontos percentuais entre grupos. Mitigações: vocabulário de domínio, ajuste fino com dados regionais autorizados e confirmação reforçada quando a confiança for baixa.

4 Integração com as disciplinas da Sprint

Tabela 8 — Quadro de integração com as demais disciplinas

Disciplina	Entrega da Sprint 1	Critério de governança aplicado
AI for RPA	Robô que captura e-mails/planilhas, classifica com IA e encaminha (SmartDeskAI)	Revisão humana para risco e baixa confiança; log por etapa; função de voz só grava após "confirmar".
Generative AI	Blueprint com agentes e Guardião de Governança	RAG só em base aprovada; RBAC antes da recuperação; confirmação por criticidade.
PLN	Taxonomia de intenções, entidades e corpus anotado	Cada intenção traz criticidade e exige_confirmacao; esclarecimento em ambiguidade; corpus sem dados reais de vítimas.
Front-end	Base do app e MVP preparatório	Cartão de confirmação editável; distinção visual entre dado relatado, inferido e faltante; aviso de privacidade.
Visão Computacional	Datasets e arquitetura do modelo visual	Human-in-the-loop antes de gravar; anonimização de placas e rostos; nenhuma detecção vira registro sozinha.
IoT	Wake word e sensores no ESP32	Wake word reduz captura de áudio ambiente; processamento local; telemetria marcada como não validada.

Fonte: Elaborado pelos autores (2026)

5 Roteiro de interação governada

O storyboard mostra (1) um registro de ocorrência com confirmação antes do envio e (2) a mesma ocorrência consultada por duas personas com visões diferentes, aplicando a matriz de permissões.

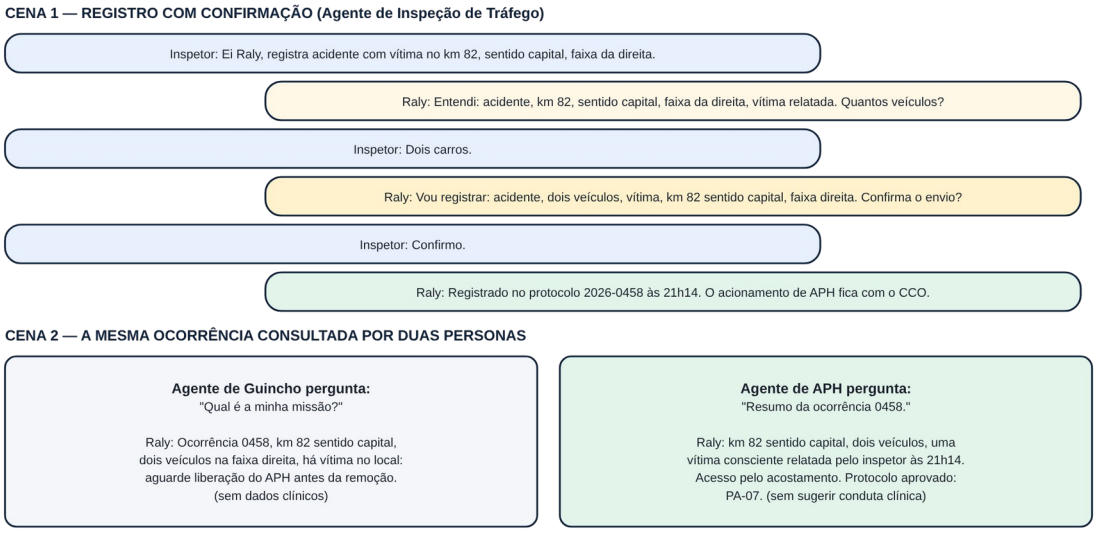


Figura 2 *— Storyboard de diálogo do registro e da consulta por duas personas. Fonte: Elaborado pelos autores (2026).*

Tabela 9 — Critérios evidenciados no storyboard

Momento	Critério aplicado
Agente repete km, sentido e faixa antes de gravar	Confirmação (critério transversal 2)
Pergunta apenas "Quantos veículos?"	Esclarecimento com uma pergunta por vez
"O acionamento de APH fica com o CCO"	Limite da IA: não aciona nem promete socorro
Guincho ouve "há vítima", sem dados clínicos	Menor privilégio e LGPD art. 11
APH ouve o protocolo aprovado, sem sugestão de conduta	Limite clínico e controle de alucinação
Cada fala gera evento no log	Rastreabilidade (critério transversal 3)

Fonte: Elaborado pelos autores (2026)

6 Considerações finais

Os critérios definidos fazem com que o Raly apoie o profissional sem assumir decisões críticas: o acesso segue o menor privilégio por persona, os dados têm finalidade e base legal declaradas, toda interação deixa rastro auditável e as ações que mobilizam recursos dependem de confirmação humana. Nas próximas sprints, este relatório será revisado com resultados reais do protótipo — em especial a medição de viés por sotaque, os prazos de retenção validados com o DPO e a evolução da RACI à medida que novas integrações forem aprovadas.

Vídeo de defesa: inserir o link do YouTube não listado após a publicação.
Repositório: inserir o endereço do GitHub privado da equipe.

Referência normativa: BRASIL. Lei nº 13.709, de 14 de agosto de 2018 (LGPD). Texto oficial: Presidência da República, Planalto. Disponível em: planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 20 out. 2026.

Declaração de uso de IA

A equipe utilizou Claude e ChatGPT como apoio à organização de ideias, ao aprofundamento dos conhecimentos e à estruturação e revisão do relatório. As matrizes RACI e de confirmação humana foram discutidas, ajustadas e validadas pelos integrantes, que assumem a responsabilidade pelas decisões finais e pelo conteúdo entregue.